

이질 그래프 기반 양성-미표기 학습을 활용한 약물 재창출 링크 예측

Heterogeneous Graph-Based Positive-Unlabeled Learning for Drug Repurposing Link Prediction

요약

본 연구는 이질 생물의학 지식 그래프(Heterogeneous Knowledge Graph) 환경에 PU(Positive-Unlabeled) 학습을 안정적으로 적용하기 위한 최초의 프레임워크인 HeteroPULL을 제안한다. 기존 링크 예측 방법은 관찰되지 않은 약물-질병 쌍을 음성(Negative)으로 간주하여 아직 발견되지 않은 잠재적 치료 관계를 무시하는 한계가 있다. 제안하는 모델은 Heterogeneous Graph Transformer(HGT)를 인코더로 활용하여 다양한 생물학적 개체 간의 복잡한 상호작용을 포착하고 신뢰도 기반 그래프 확장(Certainty-aware expansion)을 통해 부족한 양성 시그널을 보강한다. 확장 과정에서 발생하는 오류 누적을 제어하기 위해 이중 손실(Dual-loss) 구조를 도입하여 학습의 안정성을 확보하였다. Hetionet 데이터셋 실험 결과, 제안 방법이 기존 동질/이질 그래프 모델뿐만 아니라 최신 PU 학습 베이스라인들을 상회하는 우수한 성능을 입증하였다.

1. 서론

약물 재창출(drug repurposing)은 기존 승인 약물의 새로운 치료 적응증을 발견하는 접근법으로 신약 개발에 비해 비용과 시간을 크게 절감할 수 있다[1]. 최근 생물학적 지식 그래프(knowledge graph)를 활용한 링크 예측 기반 약물 재창출이 주목받고 있으며, 이를 통해 약물-질병 간 잠재적 치료 관계를 체계적으로 탐색할 수 있다.

그러나 기존 방법들은 두 가지 근본적인 한계를 가진다. 첫째, 대부분의 링크 예측 모델은 관찰되지 않은 약물-질병 쌍을 음성 샘플로 간주하여 학습한다. 그러나 이러한 미관찰 데이터에는 아직 검증되지 않았을 뿐 실제로는 유효한 치료 관계가 숨어있을 수 있다. 이처럼 미표기 데이터를 모두 음성으로 취급하는 것은 표준 지도 학습의 가정을 위배하여 심각한 편향을 초래하기 때문에 최근 이를 해결하기 위한 양성-미표기(Positive-Unlabeled) 학습[2]이 주목받고 있다. 둘째, Hetionet[3]과 같은 생물학적 지식 그래프는 약물, 유전자, 질병, 경로 등 다양한 유형의 노드와 관계를 포함하는 이질 그래프(heterogeneous graph)이나, 기존 PU 학습 연구[4]는 주로 동질 그래프에 한정되어 있어 이질 그래프의 풍부한 의미 정보를 충분히 활용하지 못한다.

본 연구에서는 이러한 한계를 해결하기 위해

HeteroPULL 프레임워크를 제안한다. 제안 방법은 (1) HGT[5]를 인코더로 활용하여 이질 그래프의 다양한 노드 및 관계 유형별 어텐션을 학습하고, (2) 모델 예측의 신뢰도에 기반한 점진적 그래프 확장을 통해 유사 양성 샘플을 추가하며, (3) 보정 손실을 통해 원래 양성 레이블에 대한 학습을 유지함으로써 유사 레이블의 오류 누적을 방지한다. 또한 화합물 노드에 Morgan fingerprint[6]를 초기 특징으로 활용하여 화학 구조 정보를 그래프 학습에 통합한다.

2. 제안 방법

2.1 문제정의

이질 생물학적 지식 그래프 $G=(V, E)$ 에서 V 는 다양한 유형(약물, 질병, 유전자 등)의 노드 집합이고, E 는 다양한 관계 유형의 엣지 집합이다. 본 연구의 목표는 관찰된 약물-질병 치료 관계(treats)만을 양성으로, 나머지를 미표기(unlabeled)로 취급하여, 새로운 치료 관계를 예측하는 것이다.




그림 1. 프레임워크 전개도

2.2 HGT 기반 인코더

제안 모델은 HGT[5]를 인코더로 사용한다. 생물의학 지식 그래프는 약물, 질병, 유전자 등 서로 다른 유형의 노드로 구성된다. 그러나 GCN이나 SAGE와 같은 동질 그래프 모델은 모든 노드를 동일한 유형으로 취급하기 때문에, 이러한 풍부한 이질적(Heterogeneous) 정보를 활용하지 못한다는 단점이 있다. HGT는 각 노드와 엣지의 유형 정보를 어텐션 가중치 계산에 명시적으로 반영하여 각각의 관계가 서로 다른 의미를 가진다는 점을 모델이 구분할 수 있도록 한다. 화합물 노드는 RDKit을 통해 생성된 512비트 Morgan fingerprint(반경=2)를 선형 변환하여 초기 특징으로 사용하고, 질병 등 기타 노드는 학습 가능한 임베딩 테이블로 초기화한다.

L개의 HGT 레이어를 거쳐 노드 및 엣지 유형별 어텐션 기반 메시지 패싱을 수행하고 최종 임베딩 z_v 를 얻는다. 약물-질병 쌍의 예측 점수는 두 노드 임베딩의 내적으로 계산한다.

$$s(c, d) = z_c^T \cdot z_d, \quad z_v = W_{out} \cdot h_v^{(L)} + b_{out}$$

2.3 신뢰도 기반 그래프 확장

학습 초기에는 관찰된 treats 엣지만으로 그래프를 구성하며 두 번째 에포크부터는 모델 예측의 신뢰도를 기반으로 유사 양성(pseudo-positive) 엣지를 점진적으로 추가한다. 여기서 신뢰도는 HGT 인코더가 산출한 약물-질병 임베딩의 내적을 시그모이드로 변환한 예측 확률 $conf(c, d) = \sigma(z_c^T z_d) \in [0, 1]$ 로 정의하며, 값이 클수록 모델이 해당 쌍의 치료 관계를 강하게 예측함을 의미한다. 매 에포크마다, 전체 약물-질병 후보 쌍 중 신뢰도가 임계값 τ 를 초과하는 쌍에 한해 상위 K개를 선택하여 유사 양성 엣지로 그래프에 편입한다. 임계값 τ 는 노이즈 엣지 유입을 차단하기 위한 품질 하한으로 작동하며, 본 실험에서는 $\tau = 0.90$ 로 설정한다. 확장

상한 K는 매 에포크 원본 양성 엣지 수의 $r = 0.03$ 비율로 점진적으로 증가하되, 누적 확장 규모가 원본 엣지 수를 초과하지 않도록 제한된다.

새로 추가되는 각 유사 양성 엣지에는 해당 시그모이드 확률 $conf(c, d)$ 를 그대로 소프트 가중치(soft weight)로 부여한다. 소프트 가중치는 신뢰도가 낮은 샘플의 학습 기여도를 줄여 오분류 영향을 완화한다.

2.4 이중 손실 함수

제안 방법은 PULL[4]을 기반으로 한 이중 손실 구조를 사용한다. 기대 그래프 손실 L_E 는 확장된 그래프(원래 엣지 + 유사 양성 엣지)에 대해 가중 이진 교차 엔트로피로 계산되며, 유사 양성 엣지에는 소프트 가중치를 적용한다.

$$L_E = - \sum_{(c, d) \in E_{exp}} w(c, d) \log \sigma(s(c, d)) - \sum_{(c, d) \in N} \log(1 - \sigma(s(c, d)))$$

보정 손실 L_C 는 원래의 관찰된 양성 엣지에 대해서만 표준 BCE로 계산된다. 그래프가 점진적으로 확장됨에 따라 모델이 새롭게 추가된 유사 양성 샘플의 노이즈에 과적합되어 원래의 확실한 치료 관계를 잊어버리거나 해당 예측 점수가 오히려 낮아지는 치명적인 문제를 겪을 수 있다. L_C 는 이러한 현상을 방지하고 모델이 노이즈가 섞인 확장 그래프를 학습하는 동안에도 올바른 방향성을 잃지 않도록 강력한 앵커(Anchor) 역할을 수행하여 유사 레이블 오류의 누적을 억제한다.

$$L_{Total} = L_E + \lambda_c \cdot L_C$$

최종 목적 함수는 두 손실의 가중합이며 $\lambda_c = 1.0$ 을 사용한다.

3. 실험

3.1 데이터셋 및 실험 설정

실험에는 Hetionet v1.0[3] 데이터셋을 사용하였다. Hetionet은 약 47,000개 노드(11개 유형)와 2,250,000개 엣지(24개 관계 유형)로 구성된 대규모 이질 생물의학 지식 그래프이다. 본 연구의 예측 대상인 약물-질병 치료 관계(Compound-treats-Disease)는 총 755개로, 가능한 전체 쌍의 약 0.4%에 불과하여 매우 희소하다. 모델 설정은 hidden_dim=128, out_dim=64, heads=4, layers=2이며, Adam 옵티마이저(lr=0.003), 50 에포크, patience=15의 조기 종료를 적용하였다. 모든 실험은 5개의 랜덤 시드(0~4)에 대해 반복 수행하였으며, 평균±표준편차를 보고한다.

3.2 성능 비교

Method	AUC	AUPRC	MRR	Hits@3	Hits@10
nnPU	0.721±0.06	0.733±0.063	0.052±0.034	0.032±0.050	0.091±0.114
PULL	0.847±0.044	0.855±0.042	0.157±0.029	0.192±0.024	0.339±0.059
GCN	0.845±0.036	0.858±0.043	0.169±0.024	0.181±0.043	0.352±0.056
SAGE	0.854±0.057	0.854±0.056	0.202±0.018	0.229±0.039	0.400±0.045
HGT	0.869±0.044	0.887±0.034	0.231±0.026	0.252±0.034	0.424±0.048
Ours	0.892±0.050	0.898±0.046	0.246±0.031	0.267±0.022	0.467±0.059

표 1. 모델별 성능 비교

표 1은 제안 모델과 기존 대표 그래프 신경망 모델들의 성능 비교 결과를 보여준다. 본 실험 환경은 양성 샘플이 희소한 PU 학습 설정이므로, 클래스 불균형에 강건한 AUPRC를 주요 평가 지표로 고려한다.

제안 모델 HeteroPULL은 AUPRC 0.898로 모든 비교 모델 중 최고 성능을 기록하였다. 이는 PU 학습 기반 모델인 nnPU(0.733)[7], PULL(0.855) 대비 각각 +16.5%p, +4.3%p의 개선이며, 동종 그래프 기반 GCN(0.858), SAGE(0.854) 대비 각각 +4.0%p, +4.4%p, 이질 그래프 기반 HGT(0.887) 대비 +1.1%p 개선을 보였다.

특히 순위 기반 지표인 Hits@10에서 0.467, MRR에서 0.246으로 기존 모델들을 큰 폭으로 상회하는 최고 값을 달성하였다. 이는 이질 그래프 구조와 PU 학습 프레임워크의 결합이 희소한 링크 예측 환경에서 유의미한 치료 관계 후보를 최상위권으로 끌어올리는 데 매우 효과적임을 보여준다.

3.3 구성 요소 분석

Method	AUC	AUPRC	MRR	Hits@3	Hits@10
w/o L_C	0.875±0.039	0.885±0.037	0.218±0.025	0.233±0.035	0.427±0.051
w/o Expansion	0.887±0.024	0.896±0.024	0.233±0.020	0.247±0.021	0.436±0.043
w/o MorganFP	0.886±0.047	0.899±0.038	0.216±0.034	0.237±0.052	0.429±0.037
Ours	0.892±0.050	0.898±0.046	0.246±0.031	0.267±0.022	0.467±0.059

표 2. 구성 요소 분석 실험 결과

표 2는 HeteroPULL의 각 구성 요소를 제거한 ablation 실험 결과이다. 보정 손실 L_C 를 제거한 경우 모든 지표에서 일관된 하락이 나타났다. 이는 L_C 가 유사 양성 오류 누적을 억제하는 핵심 앵커 역할을 수행함을 보여준다.

Morgan fingerprint 제거 시 AUC와 AUPRC는 각각 0.886과 0.899로 전체 모델과 유사한 수준을 유지하였다. 그러나 순위 기반 지표인 MRR은 0.246에서 0.216으로, H@10은 0.467에서 0.429로 뚜렷하게 하락하였다. 이를 통해 화학 구조 정보가 최상위 K개 예측 후보의 정확도를 높이는 데 핵심적으로 기여함을

확인하였다.

그래프 확장을 제거한 조건(w/o Expansion)에서는 AUC가 0.892에서 0.887로, AUPRC가 0.898에서 0.896으로, MRR이 0.246에서 0.233으로, Hits@10이 0.467에서 0.436으로 일제히 하락하였다. 이는 엄격한 임계값($\tau = 0.90$) 설정을 통해 고품질의 유사 양성 엣지만을 선별하여 점진적으로 확장한 전략이, 희소한 데이터 환경에서도 효과적인 추가 학습 신호를 제공하여 전반적인 성능 향상에 크게 기여하였음을 입증한다.

4. 결론 및 향후 연구

본 연구는 이질 지식 그래프의 풍부한 의미 정보와 PU 학습을 결합한 최초의 약물 재창출 프레임워크인 HeteroPULL을 제안하였다. 화학 구조 정보(Morgan fingerprint)와 HGT 기반 인코더를 통해 개체 간의 복잡한 상호작용을 포착하였으며, 신뢰도 기반 그래프 확장 및 이중 손실 함수를 도입하여 노이즈에 강건한 링크 예측 성능을 달성하였다. 향후에는 제안된 모델을 더 다양하고 규모가 큰 생물학적 데이터셋에 교차 적용해 범용성을 확인하고, 실제 임상 적용을 위한 후보 약물 검증 연구로 확장할 예정이다.

참고문헌

[1] S. Pushpakom et al., "Drug repurposing: progress, challenges and recommendations," *Nature Reviews Drug Discovery*, vol. 18, pp. 41-58, 2019.

[2] J. Bekker and J. Davis, "Learning from positive and unlabeled data: A survey," *Machine Learning*, vol. 109, no. 4, pp. 719-760, 2020.

[3] D. S. Himmelstein et al., "Systematic integration of biomedical knowledge prioritizes drugs for repurposing," *eLife*, vol. 6, p. e26726, 2017.

[4] J. Kim, K. H. Park, H. Yoon, and U. Kang, "Accurate Link Prediction for Edge-Incomplete Graphs via PU Learning," in *Proceedings of AAAI*, 2025.

[5] Z. Hu, Y. Dong, K. Wang, and Y. Sun, "Heterogeneous Graph Transformer," in *Proceedings of WWW*, pp. 2704-2710, 2020.

[6] D. Rogers and M. Hahn, "Extended-Connectivity Fingerprints," *Journal of Chemical Information and Modeling*, vol. 50, no. 5, pp. 742-754, 2010.

[7] R. Kiryo, G. Niu, M. C. du Plessis, and M. Sugiyama, "Positive-Unlabeled Learning with Non-Negative Risk Estimator," in *Proceedings of NeurIPS*, 2017.